4.9

4.9 분류 실습 - 캐글 산탄데르 고객 만족 예측

데이터 전처리

1. train_santander.csv 로드 후 학습 데이터 DataFrame으로 로딩
2. 변수별 특징 및 분포 이해를 통한 데이터 분석 : 데이터 범위가 너무 큰 변수들은 피처 드롭
3. 학습/테스트 데이터 split

XGBoost 모델 학습과 하이퍼 파라미터 튜닝

n_estimators = 500, early_stopping_rounds =100

1. 테스트 데이터 셋을 통한 ROC AUC 예측
2. 베이지안 최적화 기반을 통한 하이퍼 파라미터 튜닝 수행 : fimin() 함수 호출을 이용해 하이퍼 파라미터 도출
3. 최적 하이퍼 파라미터를 기반으로 XGBClassifer 재학습 후 테스트 데이터세트에서 ROC AUC 측정
4. 각 피처 중요도 파악을 위한 plot_importance()

LightGBM 모델 학습과 하이퍼 파라미터 튜닝

n_estimators = 500, early_stopping_rounds =100

1. 테스트 데이터 셋을 통한 ROC AUC 예측 (XGBoost 대비 시간 단축)
2. 베이지안 최적화 기반을 통한 하이퍼 파라미터 튜닝 수행 : fimin() 함수 호출을 이용해 하이퍼 파라미터 도출

Decision Tree And Random Forest Classifier Models

데이터 전처리

1. 고객 이탈(Churn) 데이터 로드 후 DataFrame으로 저장
2. 변수 타입 및 데이터 구조 확인
3. 분류 문제에 맞게 범주형 변수들을 적절히 변환 : 문자형 변수 → factor / category 형태로 변환
4. 예측에 불필요한 식별자 변수 제거 & 결측치 여부 확인
5. 학습/테스트 데이터 분리

Decision Tree 모델 학습 및 튜닝

1. 학습/테스트 데이터 split
2. 기본 모델 성능 평가
3. 하이퍼파라미터 튜닝 수행 : cp, expand.grid() 조정
4. 최적 파라미터 기반으로 모델 재학습
5. 변수 중요도 확인 : 어떤 변수가 예측에 중요한지 해석

Random Forest 모델 학습 및 튜닝

1. 분류 모델 생성 및 학습
2. 테스트 데이터 셋에 대한 예측 수행
3. 모델 성능 평가
4. 변수 중요도 확인
5. OOB(Out-of-Bag) Error 확인
6. 주요 하이퍼파라미터 튜닝
7. 튜닝 후 성능 재평가

모델 성능 비교 및 해석

1. Decision Tree vs Random Forest 성능 비교
2. 어떤 모델이 더 높은 정확도를 보이는지 확인
3. 변수 중요도를 바탕으로 핵심 예측 변수 해석
4. 최종적으로 Random Forest가 더 안정적이고 성능이 우수한지 판단

Beginner Friendly CATBOOST with OPTUNA

데이터 전처리

1. 학습용 데이터셋 로드 후 DataFrame으로 저장
2. 데이터 구조 및 변수 타입 확인 : 수치형 변수 / 범주형 변수 구분
3. 타깃 변수 확인
4. 결측치 및 이상치 여부 확인
5. CatBoost에 사용할 범주형 변수 지정
6. 학습/검증(또는 학습/테스트) 데이터 분리

CatBoost 기본 모델 학습

1. CatBoostClassifier 기본 모델 생성
2. 학습 데이터로 모델 학습 수행
3. 검증 데이터셋에 대해 예측 수행
4. 기본 성능 평가 : 정확도(Accuracy), ROC AUC, F1-score 등 확인
5. 기본 모델 성능을 베이스라인(Baseline) 으로 저장

Optuna를 활용한 하이퍼파라미터 튜닝

1. 목적 함수 정의
2. 탐색할 주요 하이퍼파라미터 범위 설정
3. trial.suggest() 함수를 사용하여 탐색 공간(search space) 정의

4. 평가 지표를 기준으로 최적화 수행 : ROC AUC 최대화 / Log Loss 최소화
5. 최적 하이퍼파라미터 추출

최적 파라미터 기반 CatBoost 재학습

1. Optuna로 찾은 최적 하이퍼파라미터를 사용하여 CatBoostClassifier 재생성
2. 전체 학습 데이터 또는 train set으로 다시 학습
3. 검증/테스트 데이터셋에 대해 최종 예측 수행
4. 최종 성능 평가
    - ROC AUC
    - Accuracy
    - Precision / Recall / F1-score 등 확인
5. 기본 모델 대비 성능 향상 여부 비교

피처 중요도 확인

1. CatBoost의 피처 중요도 추출
2. 어떤 변수가 예측에 가장 큰 영향을 주는지 확인
3. 중요 변수 시각화 : bar plot 또는 importance plot 활용
4. 모델 해석 및 변수 영향력 분석

모델 성능 비교 및 해석

1. 기본 CatBoost 모델 vs Optuna 튜닝 CatBoost 모델 비교
2. 하이퍼파라미터 튜닝이 실제로 성능 향상에 기여했는지 확인
3. overfitting 여부 점검
4. 최종적으로 가장 성능이 좋은 CatBoost 모델 선택